

Επεξεργασίας Φυσικής Γλώσσας - Άσκηση 1

Ευφροσύνη Ναλμπάντη

Μάρτιος 2026

1 Σκοπός

Αντικείμενο της εργασίας αυτής είναι η ανάπτυξη προγράμματος Python που εξάγει αυτόματα δεδομένα από σελίδες πόλεων στην Wikipedia, χρησιμοποιώντας αποκλειστικά κανονικές εκφράσεις (module re). Το πρόγραμμα δέχεται ως είσοδο ένα URL Wikipedia και επιστρέφει δομημένες πληροφορίες για την πόλη. Οι πληροφορίες που εξάγονται είναι:

- Όνομα πόλης
- Πληθυσμός
- Έκταση
- Χώρα / Περιφέρεια
- Γεωγραφικές συντεταγμένες
- Υψόμετρο
- Ζώνη ώρας
- Μέγιστη/ελάχιστη/μέση θερμοκρασία έτους

2 Μεθοδολογία


Το πρόγραμμα ακολουθεί αρθρωτή (modular) σχεδίαση. Κάθε πεδίο εξάγεται από ξεχωριστή συνάρτηση, ενώ υπάρχουν και βοηθητικές συναρτήσεις για καθαρισμό κειμένου και λήψη HTML. Η ροή εκτέλεσης είναι:

1. Λήψη HTML από το URL με urllib.request
2. Εφαρμογή κανονικών εκφράσεων στο ακατέργαστο HTML για εξαγωγή τιμών
3. Καθαρισμός και κανονικοποίηση εξαγόμενων τιμών
4. Εκτύπωση αποτελεσμάτων

Επιλέχθηκαν σελίδες από την ελληνική Wikipedia ως πηγή δεδομένων. Το όνομα της πόλης, ο πληθυσμός, η έκταση, η χώρα/περιφέρεια, το υψόμετρο και η ζώνη ώρας ελήφθησαν μέσα από html από το info box κάθε σελίδας. Η θερμοκρασία ελήφθηκε από την καρτέλα στα περιεχόμενα το "Κλίμα" όπου περιελάμβανε αντίστοιχους πίνακες. Για την υψηλότερη θερμοκρασία ελήφθηκε η υψηλότερη μέγιστη, για τη χαμηλότερη η χαμηλότερη ελάχιστη και για τη μέση η μέση μηνιαία.

3 Παραδείγματα - Στιγμιότυπα Οθόνης

3.1 Ορεστιάδα



```
Γραμμή εντολών
C:\Users\User\Desktop>"C:\Users\User\AppData\Local\Programs\Python\Python311\python.exe" aid26014_hw1.py
Εισάγετε URL πόλης: https://el.wikipedia.org/wiki/%CE%9F%CF%81%CE%B5%CF%83%CF%84%CE%B9%CE%AC%CE%84%CE%B1

Λήψη σελίδας...
ΠΛΗΡΟΦΟΡΙΕΣ ΠΟΛΗΣ
Όνομα πόλης      : Ορεστιάδα
Πληθυσμός        : 18.164
Έκταση           : 967,5 km²
Χώρα/Περίφεια    : Ελλάδα
Συντεταγμένες    : 41.5030611°N, 26.5297194°E
Υψόμετρο          : 44 μ.
Ζώνη ώρας         : Δεν βρέθηκε
Μέση μηνιαία     : 14.83 °C
```

Σχήμα 1: Ορεστιάδα

3.2 Θεσσαλονίκη

```
Λήψη σελίδας...
ΠΛΗΡΟΦΟΡΙΕΣ ΠΟΛΗΣ
Όνομα πόλης      : Θεσσαλονίκη
Πληθυσμός        : 802.392
Εκταση           : 19,3 km²
Χώρα/Περιφέρεια  : Δεν βρέθηκε
Συντεταγμένες   : 40.64028°N, 22.93556°E
Υψόμετρο         : 6 μ.
Ζώνη ώρας        : Θερινή: [[UTC+03:00]]&quot;}},&quot;i&qu
Υψηλότερη Μέγιστη: 44.0 °C
Μέση Μηνιαία    : 7.0 °C
Χαμηλότερη Ελάχ. : -1.0 °C
```

Σχήμα 2: Θεσσαλονίκη

3.3 Αθήνα

```
C:\Users\User\Desktop>"C:\Users\User\AppData\Local\Programs\Python\Python311\python.exe" aid26014_hw1.py
Εισάγετε URL πόλης: https://el.wikipedia.org/wiki/%CE%91%CE%B8%CE%AE%CE%B0%CE%B1

Λήψη σελίδας...
ΠΛΗΡΟΦΟΡΙΕΣ ΠΟΛΗΣ
Όνομα πόλης      : Αθήνα
Πληθυσμός        : 637.798
Εκταση           : 1950 km²
Χώρα/Περιφέρεια  : Δεν βρέθηκε
Συντεταγμένες   : 37.98417°N, 23.72806°E
Υψόμετρο         : 170 μ.
Ζώνη ώρας        : Όρα Ανατολικής Ευρώπης
Υψηλότερη Μέγιστη: 44.8 °C
Μέση Μηνιαία    : 25.0 °C
Χαμηλότερη Ελάχ. : -4.0 °C
```

Σχήμα 3: Αθήνα

3.4 Παρίσι

```
C:\Users\User\Desktop>"C:\Users\User\AppData\Local\Programs\Python\Python311\python.exe" aid26014_hw1.py
Εισάγετε URL πόλης: https://el.wikipedia.org/wiki/%CE%A0%CE%B1%CF%81%CE%AF%CF%83%CE%B9

Λήψη σελίδας...
ΠΛΗΡΟΦΟΡΙΕΣ ΠΟΛΗΣ
Όνομα πόλης      : Παρίσι
Πληθυσμός        : 2.103.778
Εκταση           : 105,4 km²
Χώρα/Περιφέρεια  : Γαλλία
Συντεταγμένες   : 48.85667°N, 2.35222°E
Υψόμετρο         : 484 μ.
Ζώνη ώρας        : UTC+01:00
Υψηλότερη Μέγιστη: 21.0 °C
Μέση Μηνιαία    : 12.5 °C
Χαμηλότερη Ελάχ. : -14.0 °C
=====
```

Σχήμα 4: Παρίσι

3.5 Νέα Υόρκη

```
C:\Users\User\Desktop>"C:\Users\User\AppData\Local\Programs\Python\Python311\python.exe" aid26014_hw1.py
Εισάγετε URL πόλης: https://el.wikipedia.org/wiki/%CE%9D%CE%AD%CE%B1_%CE%A5%CF%8C%CF%81%CE%BA%CE%B7

Λήψη σελίδας...
  ΠΛΗΡΟΦΟΡΙΕΣ ΠΟΛΗΣ
Όνομα πόλης      : Νέα Υόρκη
Πληθυσμός        : 8.804.190
Εκταση           : 1.213,369839 km²
Χώρα/Περιφέρεια  : Δεν βρέθηκε
Συντεταγμένες   : 40°N, 42°E
Υψόμετρο         : 255 μ.
Ζώνη ώρας        : ανατολική ζώνη ώρας
  Υψηλότερη Μέγιστη: 41.0 °C
  Χαμηλότερη Ελάχ. : -26.0 °C
```

Σχήμα 5: Νέα Υόρκη

3.6 Μόναχο

```
C:\Users\User\Desktop>"C:\Users\User\AppData\Local\Programs\Python\Python311\python.exe" aid26014_hw1.py
Εισάγετε URL πόλης: https://el.wikipedia.org/wiki/%CE%9C%CF%8C%CE%BD%CE%B1%CF%87%CE%BF

Λήψη σελίδας...
  ΠΛΗΡΟΦΟΡΙΕΣ ΠΟΛΗΣ
Όνομα πόλης      : Μόναχο
Πληθυσμός        : 1.348.650
Εκταση           : 310,43 km²
Χώρα/Περιφέρεια  : "}}>
Συντεταγμένες   : 48.1397°N, 11.5744°E
Υψόμετρο         : 519 μ.
Ζώνη ώρας        : Δεν βρέθηκε
```

Σχήμα 6: Μόναχο

3.7 Χιλή

```
=====
C:\Users\User\Desktop>"C:\Users\User\AppData\Local\Programs\Python\Python311\python.exe" aid26014_hw1.py
Εισάγετε URL πόλης: https://el.wikipedia.org/wiki/%CE%A7%CE%B9%CE%BB%CE%AE

Λήψη σελίδας...
  ΠΛΗΡΟΦΟΡΙΕΣ ΠΟΛΗΣ
Όνομα πόλης      : Χιλή
Πληθυσμός        : 17.574.003
Εκταση           : 756.102 km²
Χώρα/Περιφέρεια  : Δεν βρέθηκε
Συντεταγμένες   : 33°N, 26°E
Υψόμετρο         : 600 μ.
Ζώνη ώρας        : &nbsp;
=====
```

Σχήμα 7: Χιλή

3.8 Μελβούρνη

```
C:\Users\User\Desktop>"C:\Users\User\AppData\Local\Programs\Python\Python311\python.exe" aid26014_hw1.py
Εισάγετε URL πόλης: https://el.wikipedia.org/wiki/%CE%99%CE%B5%CE%BB%CE%B2%CE%BF%CF%8D%CF%81%CE%B0%CE%B7

Λήψη σελίδας...
ΠΛΗΡΟΦΟΡΙΕΣ ΠΟΛΗΣ
Όνομα πόλης      : Μελβούρνη
Πληθυσμός       : 5.350.705
Εκταση          : 9.993 km²
Χώρα/Περιφέρεια : Αυστραλία
Συντεταγμένες  : 37°N, 48°E
Υψόμετρο        : 31 μ.
Ζώνη ώρας       : UTC+10:00
Υψηλότερη Μέγιστη: 46.4 °C
Μέση Μηνιαία   : 17.9 °C
Χαμηλότερη Ελάχ. : -13.2 °C
```

Σχήμα 8: Μελβούρνη

3.9 Σεϋχέλλες

```
C:\Users\User\Desktop>"C:\Users\User\AppData\Local\Programs\Python\Python311\python.exe" aid26014_hw1.py
Εισάγετε URL πόλης: https://el.wikipedia.org/wiki/%CE%A3%CE%B5%CF%8B%CF%87%CE%AD%CE%BB%CE%BB%CE%B5%CF%82

Λήψη σελίδας...
ΠΛΗΡΟΦΟΡΙΕΣ ΠΟΛΗΣ
Όνομα πόλης      : Σεϋχέλλες
Πληθυσμός       : 4.6167
Εκταση          : Δεν βρέθηκε
Χώρα/Περιφέρεια : Δεν βρέθηκε
Συντεταγμένες  : 7.1°S 52.7667°E
Υψόμετρο        : Δεν βρέθηκε
Ζώνη ώρας       : &nbsp;
```

Σχήμα 9: Σεϋχέλλες

3.10 Σανγκάη

```
C:\Users\User\Desktop>"C:\Users\User\AppData\Local\Programs\Python\Python311\python.exe" aid26014_hw1.py
Εισάγετε URL πόλης: https://el.wikipedia.org/wiki/%CE%A3%CE%B1%CE%B3%CE%BA%CE%AC%CE%B7

Λήψη σελίδας...
ΠΛΗΡΟΦΟΡΙΕΣ ΠΟΛΗΣ
Όνομα πόλης      : Σανγκάη
Πληθυσμός       : 24.870.895
Εκταση          : 6.341 km²
Χώρα/Περιφέρεια : Λαϊκή Δημοκρατία της Κίνας
Συντεταγμένες  : 31.23250°N, 121.46917°E
Υψόμετρο        : 4 μ.
Ζώνη ώρας       : UTC+8
Υψηλότερη Μέγιστη: 39.9 °C
Μέση Μηνιαία   : 17.05 °C
Χαμηλότερη Ελάχ. : -10.1 °C
```

Σχήμα 10: Σανγκάη

4 Συμπεράσματα

Η χρήση κανονικών εκφράσεων για εξαγωγή δεδομένων από Wikipedia αποδείχθηκε εφικτή και αποτελεσματική για ελληνικές πόλεις με πλήρες infobox. Στα πλεονεκτήματα ανήκουν η εύκολη και γρήγορη υλοποίηση, η ανεξαρτησία κάθε πληροφορία που θέλουμε να εξαχθεί, η οποία δεν επηρεάζεται από το πως γίνονται οι υπόλοιπες. Αντίθετα, στα μειονεκτήματα ανήκουν η αποτυχία των κανονικών εκφράσεων να εξάγουν τις πληροφορίες που απαιτούνται γιατί είτε τα πλαίσια ανά πόλη δεν περιλαμβάνουν όλες τις ζητούμενες πληροφορίες είτε γιατί έχουν περισσότερους από έναν πίνακα για τις θερμοκρασίες είτε δεν έχουν κανέναν. Μπορεί να παράγουν τιμές από άσχετα τμήματα της σελίδας. Τα patterns δεν λειτουργούν σε άλλη γλώσσα πέρα από την ελληνική. Τέλος, δεν μπορεί να διακρίνει αν ο αριθμός που βρέθηκε αφορά πληθυσμό πόλης ή δήμου ή να παράγει όλους τους αριθμούς που αντιστοιχούν στη ζητούμενη τιμή, θερμοκρασία Κελσίου ή Φαρενάι.